

Laboratorio 16 - Análisis y Visualización

Estadística Inferencial 2026 - Terce Parcial 30%

Julio Seferino Hurtado Márquez

Email:

Celular:

Código Estudiantil

Encuesta Sysarmy

Se trabajará con la Encuesta Sysarmy del año 2022 versión 1. Se trata de una encuesta personal y voluntaria que busca relevar información sobre salarios y condiciones de trabajo de programadores, que se realiza anualmente. Se analizarán sólo los datos provenientes de Argentina

✓ Librerías para Trabrar en R

✓ Librerías para Trabrar en R

```
# @title **Librerías para Trabrar en R**  
import io  
import matplotlib  
import matplotlib.pyplot as plt  
import numpy  
import pandas as pd  
import seaborn  
  
seaborn.set_context('talk')
```

- ✓ 1. [Base de Datos](#)
- 2. [Análisis de salarios](#)
- 3. [Remover valores nulos](#)
- 4. [Visualizacion de varios Histogramas](#)
- 5. [Visualizar el conteo de cada uno de los puntos](#)
- 6. [Gráfico de líneas para la variable salary_monthly_NETO](#)
- 7. [Variables Categóricas](#)
- 8. [Ordenando Variables Categoricas](#)
- 9. [Tipos de datos vs tipos de datos](#)
- 10. [Histograma mi salario](#)
- 11. [Variables Numéricas](#)
- 12. [Relación entre Género y Nivel de Estudios](#)

13. [Análisis de puntos e Histograma](#)

14. [Perfil univariable o "depth profile" \(perfil de profundidad\)](#)

[ULTIMO](#)

[🔼 Volver al inicio](#)

1. Base de Datos

En esta primera notebook, aprendemos cómo cargar un conjunto de datos utilizando pandas y cómo ver su contenido. Durante la materia, se trabajará con la Encuesta Sysarmy del año 2022 versión 1. Se trata de una encuesta personal y voluntaria que busca relevar información sobre salarios y condiciones de trabajo de programadores, que se realiza anualmente. Se analizarán sólo los datos provenientes de Argentina

```
url = 'https://cs.famaf.unc.edu.ar/~mteruel/datasets/diplodatos/sysarmy_survey_2020_processed.csv'
df = pd.read_csv(url)
```

df[:3]

	profile_gender	profile_age	work_country	work_province	profile_years_experience	work_years_in_company	work_years_in_curr
0	Mujer	26	Argentina	Ciudad Autónoma de Buenos Aires	3.0	3.0	
1	Hombre	29	Argentina	Corrientes	5.0	2.0	
2	Mujer	22	Argentina	Ciudad Autónoma de Buenos Aires	2.0	0.0	

3 rows × 48 columns

[🔼 Volver al inicio](#)

2. Análisis de salarios


- Una primera pregunta que se nos puede ocurrir al ver esta encuesta es: "¿Y cuánto cobran los programadores en Argentina?". (advertencia de sesgo!!! se nos pueden ocurrir muchas más! cuáles?)
- Este será nuestro punto de partida para el análisis del conjunto de datos. El proceso total constará de varias iteraciones: a medida que se analicen los datos se descubrirán otros aspectos relevantes, lo cual disparará nuevas preguntas.
- Para conocer más sobre la distribución de los salarios, es necesario elegir una columna de la encuesta para analizar.

2.1. Columna de salarios

```
# @title **2.1. Columna de salarios**
salary_col = 'salary_monthly_NETO'
```

2.2. Histograma de salarios

```
# @title **2.2. Histograma de salarios**
seaborn.displot(df[salary_col], aspect=2) #cambiar los bins=5,20 0 50 y ver...
## para evitar la notación científica en las etiquetas
plt.ticklabel_format(style='plain', axis='x' )
```




[🔼 Volver al inicio](#)

✓ **2.3. Conteos de Datos que no son numéricos, datos categóricos. Pueden ser ordinales o no ordinales.**

```
# @title **2.3. Conteos de Datos que no son numéricos, datos categóricos. Pueden ser ordinales o no ordinales.**
fig = plt.figure(figsize=(10, 10))
seaborn.countplot(y=df.work_province, color='steelblue', label='Julio Hurtado')
```

<Axes: xlabel='count', ylabel='work_province'>



[Volver al inicio](#)

3. Remover valores nulos

¡Tip! Antes de graficar, controlar el rango (ya que seaborn intentará crear miles de segmentos si el rango es muy grande) y remover los valores nulos.

4.1. Obtenemos el rango de valores observados de los salarios

```
# @title **4.1. Obtenemos el rango de valores observados de los salarios**
df.profile_age.min(), df.profile_age.max()
```


```
(18, 52000)
```

4.2. Ahora analizamos la edad de los encuestados

```
# @title **4.2. Ahora analizamos la edad de los encuestados**
```

```
seaborn.displot(df.profile_age[df.profile_age < 100].dropna(),
                stat='count', aspect=4)
```

<seaborn.axisgrid.FacetGrid at 0x7ebf1c8149b0>


[🔙 Volver al inicio](#)

4. Visualización de varios Histogramas


- Sin embargo, los histogramas pueden ocultar información. ¿Por qué? Porque agrupan rangos de valores en intervalos inferidos automáticamente. Como resultado, la visualización varía con distintas longitudes de segmentos. Comparemos los siguientes histogramas.

4.1. Un ejemplo más avanzado

```
# @title **4.1. Un ejemplo más avanzado**
fig, ax = plt.subplots(nrows=2, ncols=3, figsize=(15,10), sharey='row')
seaborn.histplot(df.profile_age[df.profile_age < 100].dropna(), ax=ax[0,0],
                  stat='count')
seaborn.histplot(df.profile_age[df.profile_age < 100].dropna(), ax=ax[0,1],
                  bins=20, stat='count')
seaborn.histplot(df.profile_age[df.profile_age < 100].dropna(), ax=ax[0,2],
                  bins=5, stat='count')

seaborn.histplot(df.profile_age[df.profile_age < 100].dropna(), ax=ax[1,0],
                  stat='frequency')
seaborn.histplot(df.profile_age[df.profile_age < 100].dropna(), ax=ax[1,1],
                  bins=20, stat='frequency')
seaborn.histplot(df.profile_age[df.profile_age < 100].dropna(), ax=ax[1,2],
                  bins=5, stat='frequency')

fig.show()
```




[⬆ Volver al inicio](#)

✓ 5. Visualizar el conteo de cada uno de los puntos

- Para variables discretas puede usarse un gráfico de línea, que permite visualizar el conteo de cada uno de los puntos en el rango observado.

✓ 5.1. Un ejemplo más avanzado - Datos individuales

```
# @title **5.1. Un ejemplo más avanzado - Datos individuales**
fig, ax = plt.subplots(nrows=1, ncols=1, figsize=(18,8))
seaborn.countplot(x=df.profile_age[df.profile_age < 100], color='steelblue', label='Julio Hurtado')
plt.show()
```




[Volver al inicio](#)

6. Gráfico de líneas para la variable salary_monthly_NETO

```
fig = plt.figure(figsize=(16,4))
age_counts = df[df.profile_age < 100].profile_age.value_counts()
seaborn.lineplot(x=age_counts.index, y=age_counts.values, color='steelblue', label='Julio Hurtado')
plt.xticks(fontsize=14) # Achicamos la letra para que se vea mejor
seaborn.despine()
plt.legend()
```

<matplotlib.legend.Legend at 0x7ebf1a69d0a0>



[Volver al inicio](#)

7. Variables Categóricas


- V.A. categóricas, para datos categóricos
- Las variables categóricas toman valores de un conjunto pre-definido, usualmente pero no necesariamente finito.
- Para visualizarlas, puede usarse un gráfico de barras, que representa cada valor observado con una columna, y el conteo de ese valor con la altura de la columna.
- Las variables numéricas discretas, ¿son categóricas?

```
df.profile_gender.unique()
```

```
array(['Mujer', 'Hombre', 'Otros'], dtype=object)
```

```
fig = plt.figure(figsize=(8,6))
seaborn.countplot(df.profile_gender, color='steelblue')
```

<Axes: xlabel='count', ylabel='profile_gender'>




[🔙 Volver al inicio](#)

8. Ordenando Variables Categoricas

- Los datos categóricos pueden ser ordinales, si existe un orden lógico entre sus valores. En caso de que un orden exista, es adecuado incluirlo en el gráfico.

```
sorted_studies_levels = ['Primario', 'Secundario', 'Terciario', 'Universitario',
                        'Posgrado', 'Doctorado', 'Posdoctorado']
fig, axes = plt.subplots(ncols=2, figsize=(30,4))
g = seaborn.countplot(y=df.profile_studies_level, color='steelblue', ax=axes[0])
g = seaborn.countplot(y=df.profile_studies_level, color='steelblue', ax=axes[1],
                      order=sorted_studies_levels)
for ax in axes:
    ax.tick_params(axis='y', labelrotation=00)
```



[↑ Volver al inicio](#)

9. Tipos de datos vs tipos de datos

- Tipos de datos vs tipos de datos
- Tenemos que distinguir dos conceptos con el mismo nombre y significado similar, pero que no son iguales:
- tipo de datos - variable aleatoria es el tipo de valores que venimos hablando (numérico continuo, numérico discreto, categórico ordinal y categórico no ordinal)
- tipo de datos (computacional) es un concepto de programación que indica en qué formato se representa la información. Cuando asignamos a una variable age del programa de Python una realización de una variable aleatoria conceptual profile_age, esa variable age también tiene un tipo de Python, por ejemplo int o float.

```
age = df.profile_age.iloc[0]
type(age)
```

```
numpy.int64
```

```
print(type(3), type(3.44), type(1/3)) # 1/3 es un numero irracional
import numpy
print(numpy.iinfo('int64').min, numpy.iinfo('int64').max)
numpy.int64(numpy.iinfo('int64').max) + 1
# Traten de hacer numpy.int64(numpy.iinfo('int64').max + 1)
```

```
<class 'int'> <class 'float'> <class 'float'>
-9223372036854775808 9223372036854775807
/tmp/ipykernel_943/3591477859.py:4: RuntimeWarning: overflow encountered in scalar add
  numpy.int64(numpy.iinfo('int64').max) + 1
np.int64(-9223372036854775808)
```

```
df.dtypes[:10]
```

```
0
profile_gender      object
profile_age         int64
work_country        object
work_province       object
profile_years_experience float64
work_years_in_company float64
work_years_in_current_position float64
work_people_in_charge_of int64
profile_studies_level object
profile_studies_level_state object
```

dtype: object

[⬆ Volver al inicio](#)

10. Histograma mi salario

- Hay que tener en cuenta que las librerías de gráficos nos permitirán crear las visualizaciones que querramos, mientras los tipos de datos sean los adecuados.


```
df.loc[:, 'salary_in_usd_bool'] = \
    df.salary_in_usd.replace({'Mi sueldo está dolarizado': True}).fillna(False)
print(df.salary_in_usd.unique(), df.salary_in_usd_bool.unique())
```

```
[nan 'Mi sueldo está dolarizado'] [False  True]
/tmp/ipykernel_943/3252169078.py:2: FutureWarning: Downcasting object dtype arrays on .fillna, .ffill, .bfill is deprecated and
df.salary_in_usd.replace({'Mi sueldo está dolarizado': True}).fillna(False)
```

[⬆ Volver al inicio](#)

```
seaborn.histplot(df.salary_in_usd_bool, bins=5)
```

<Axes: xlabel='salary_in_usd_bool', ylabel='Count'>



[⬆ Volver al inicio](#)


11. Variables Numéricas

```
salary_col='salary_monthly_BRUTO'
#salary_col='salary_monthly_NETO'
```

```
fig, axes = plt.subplots(nrows=2, figsize=(16, 10))
seaborn.histplot(df[salary_col], bins=100, ax=axes[0], color='gray')
axes[0].axvline(df[salary_col].mean(), color='orangered',
               linestyle='--', label='Media')
axes[0].axvline(df[salary_col].median(), color='indigo',
               linestyle='-.', label='Mediana')

filtered_df = df[df[salary_col] < 200000]
seaborn.histplot(filtered_df[salary_col], bins=100, ax=axes[1], color='gray')
axes[1].axvline(filtered_df[salary_col].mean(), color='orangered',
               linestyle='--', label='Media')
axes[1].axvline(filtered_df[salary_col].median(), color='indigo',
               linestyle='-.', label='Mediana')

axes[0].legend()
seaborn.despine()
```



[🔙 Volver al inicio](#)


12. Relación entre Género y Nivel de Estudios

- **Gráfico 1:** Tabla de contingencia (`pd.crosstab`) de género vs. nivel de estudios.
- **Observaciones:** Proporciona los conteos brutos de la intersección de cada categoría de género y nivel de estudios. Esto permite cuantificar la composición de la muestra en cada combinación.
- **Temática:** Análisis bivariado de dos variables categóricas; visualización tabular de frecuencias conjuntas.
- **Gráfico 2:** Mapa de calor (`seaborn.heatmap`) de la tabla de contingencia.
- **Observaciones:** Muestra visualmente las combinaciones más y menos frecuentes de género y nivel de estudios. Por ejemplo, se observa que los hombres con nivel universitario son el grupo más numeroso.
- **Temática:** Visualización de la intensidad de la relación entre dos variables categóricas.
- **Gráfico 3:** Gráfico de barras agrupadas (`seaborn.countplot`) de nivel de estudios por género (`hue`).
- **Observaciones:** Permite una comparación directa de la distribución de niveles de estudio entre los diferentes géneros, revelando posibles diferencias en los perfiles educativos. Por ejemplo, se puede ver la proporción de hombres vs. mujeres en cada nivel de estudio.
- **Temática:** Comparación de distribuciones de una variable categórica condicionada por otra variable categórica.

```
## Tabla de contingencia
pd.crosstab(df.profile_gender, df.profile_studies_level)#, normalize=True)
```

profile_studies_level	Doctorado	Posdoctorado	Posgrado	Primario	Secundario	Terciario	Universitario	
profile_gender								
Hombre	19	4	256	2	424	970	3447	
Mujer	8	0	85	0	24	158	667	
Otros	3	0	1	0	1	7	19	

```
fig = plt.figure(figsize=(10,6))
exp = pd.crosstab(df.profile_gender,
                  df.profile_studies_level)[sorted_studies_levels]
seaborn.heatmap(exp, annot=True, fmt='g')
plt.suptitle('Mi Profe: Julio Hurtado', y=1.02) # Adjust y to ensure it doesn't overlap
plt.show()
```




```
## Tabla de contingencia normalizada
pd.crosstab(df.profile_gender, df.profile_studies_level, normalize=True)
```

profile_studies_level	Doctorado	Posdoctorado	Posgrado	Primario	Secundario	Terciario	Universitario	
profile_gender								
Hombre	0.003117	0.000656	0.042002	0.000328	0.069565	0.159147	0.565546	
Mujer	0.001313	0.000000	0.013946	0.000000	0.003938	0.025923	0.109434	
Otros	0.000492	0.000000	0.000164	0.000000	0.000164	0.001148	0.003117	

```
fig = plt.figure(figsize=(8,6))
seaborn.countplot(x=df.profile_studies_level, hue=df.profile_gender )
plt.xticks(rotation=45)
plt.suptitle('Mi Profe: Julio Hurtado', y=1.02) # Adjust y to ensure it doesn't overlap
plt.show()
```


Mi Profe: Julio Hurtado



[⬆ Volver al inicio](#)

13. Análisis de puntos e Histograma

```
max_age = 99
fig = seaborn.pairplot(data=df[df.profile_age < max_age],
                      y_vars=['profile_age', 'salary_monthly_BRUTO'],
                      x_vars=['salary_monthly_NETO', 'salary_monthly_BRUTO'],
                      aspect=2, height=4)
plt.suptitle('Mi Profe: Julio Hurtado', y=1.02) # Adjust y to ensure it doesn't overlap
plt.show()
```



```
seaborn.jointplot(data=df[df.profile_age < max_age], x='profile_age',
                  y='salary_monthly_NETO', kind='hex', height=6)
# Remove scientific notation
plt.ticklabel_format(style='plain', axis='y')
plt.suptitle('Mi Profe: Julio Hurtado', y=1.02) # Adjust y to ensure it doesn't overlap
plt.show()
```

